

《传播统计学》

单因素方差分析

教师：林志良

邮箱：linzhl@nfu.edu.cn

个人网站：www.zhilianglin.com

目录

- 单因素方差分析介绍
- 拆解变异：总变异，组间变异，组内变异，均方
- 例题
- 软件实操

单因素方差分析介绍

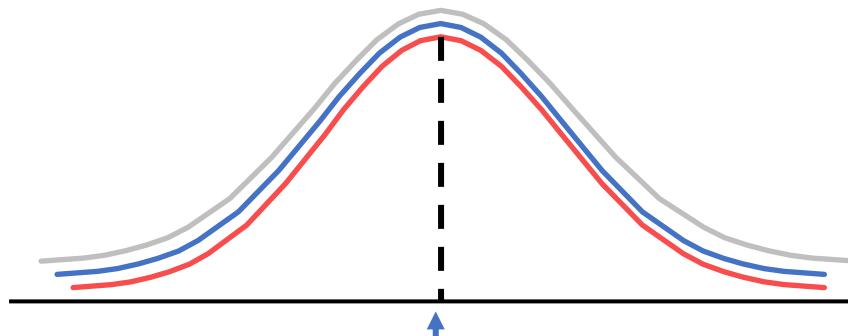
- **作用：**比较多组样本的均值
 - **适用条件：**自变量-**多类别变量**；因变量-**数值型变量**
 - **例如：**
 - 文传各专业（汉语言/新闻/网新）同学社交媒体使用时间差异
 - 不同生源地（珠三角/非珠三角省内/省外）同学英语口语能力差异
- 方差分析有多种类型，这里我们只学习**单因素方差分析**（One-way ANOVA）

Analysis of Variance

$$H_0: \mu_1 = \mu_2 = \mu_3 = \dots = \mu_c$$

H_1 : 不是所有的 μ_i 都相等的

- 如果 H_0 成立:



$$\mu_1 = \mu_2 = \mu_3$$

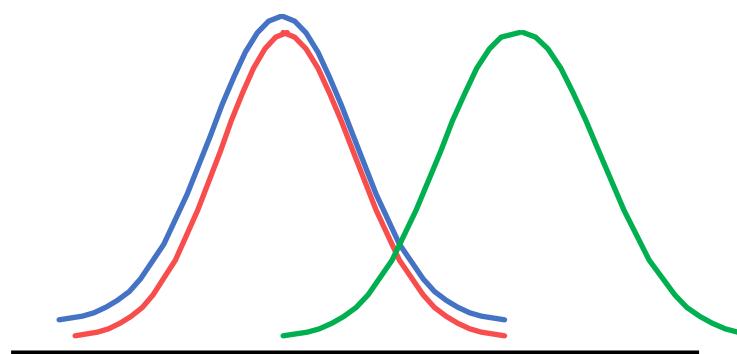
单因素方差分析介绍

假设

$$H_0: \mu_1 = \mu_2 = \mu_3 = \dots = \mu_c$$

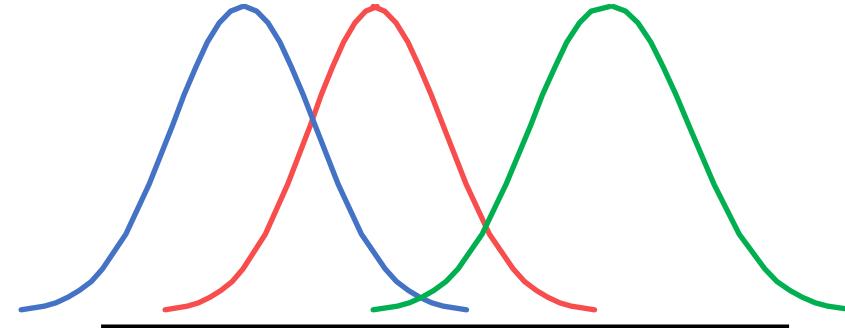
H_1 : 不是所有的 μ_i 都相等的

- 如果 H_0 不成立:



$$\mu_1 = \mu_2 \neq \mu_3$$

或



$$\mu_1 \neq \mu_2 \neq \mu_3$$

首先将总变异 ($ss_{\text{总}}$) 分解为组间变异 ($ss_{\text{组间}}$) 和组内变异 ($ss_{\text{组内}}$)，然后比较两者的平均变异 $MS_{\text{组间}}$ 和 $MS_{\text{组内}}$ ，比较时采用两者的比值F值，即：

$$F = \frac{MS_{\text{组间}}}{MS_{\text{组内}}}$$



解构变异

总变异=组间变异+组内变异

$$SS_{\text{总}} = SS_{\text{组间}} + SS_{\text{组内}}$$

$SS_{\text{总}}$

$SST = \text{Total Sum of Squares}$
(*Total variation*)

总平方和
(总变异)

$SS_{\text{组间}}$

$SSA = \text{Sum of Squares Among Groups}$
(*Among-group variation*)

组间平方和
(组间变异)

$SS_{\text{组内}}$

$SSW = \text{Sum of Squares Within Groups}$
(*Within-group variation*)

组内平方和
(组内变异)

解构变异

总变异

$$SS_{\text{总}} = SS_{\text{组间}} + SS_{\text{组内}}$$

$$SS_{\text{总}} = \sum_{i=1}^c \sum_{j=1}^{n_i} (X_{ij} - \bar{\bar{X}})^2$$

其中，

$SS_{\text{总}}$ = 总平方和

c = 组别数

n_i = 第*i*组的数据量

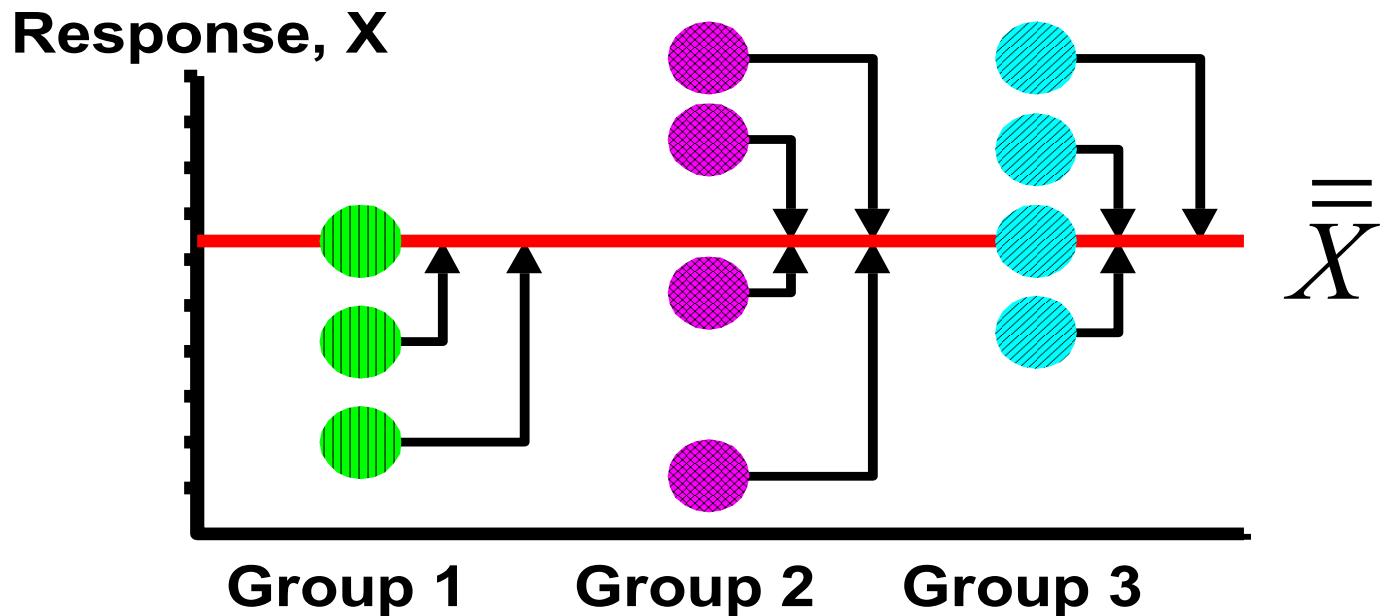
X_{ij} = 第*i*组的第*j*个观测值

$\bar{\bar{X}}$ = 所有数值的平均值

解构变异

总变异

$$SS_{\text{总}} = (X_{11} - \bar{\bar{X}})^2 + (X_{12} - \bar{\bar{X}})^2 + \dots + (X_{cn_c} - \bar{\bar{X}})^2$$



解构变异

组间变异

$$SS_{\text{总}} = SS_{\text{组间}} + SS_{\text{组内}}$$

$$SS_{\text{组间}} = \sum_{i=1}^c n_i (\bar{X}_i - \bar{\bar{X}})^2$$

其中，

$SS_{\text{组间}}$ = 组间平方和

c = 组别数

n_i = 第*i*组的数据量

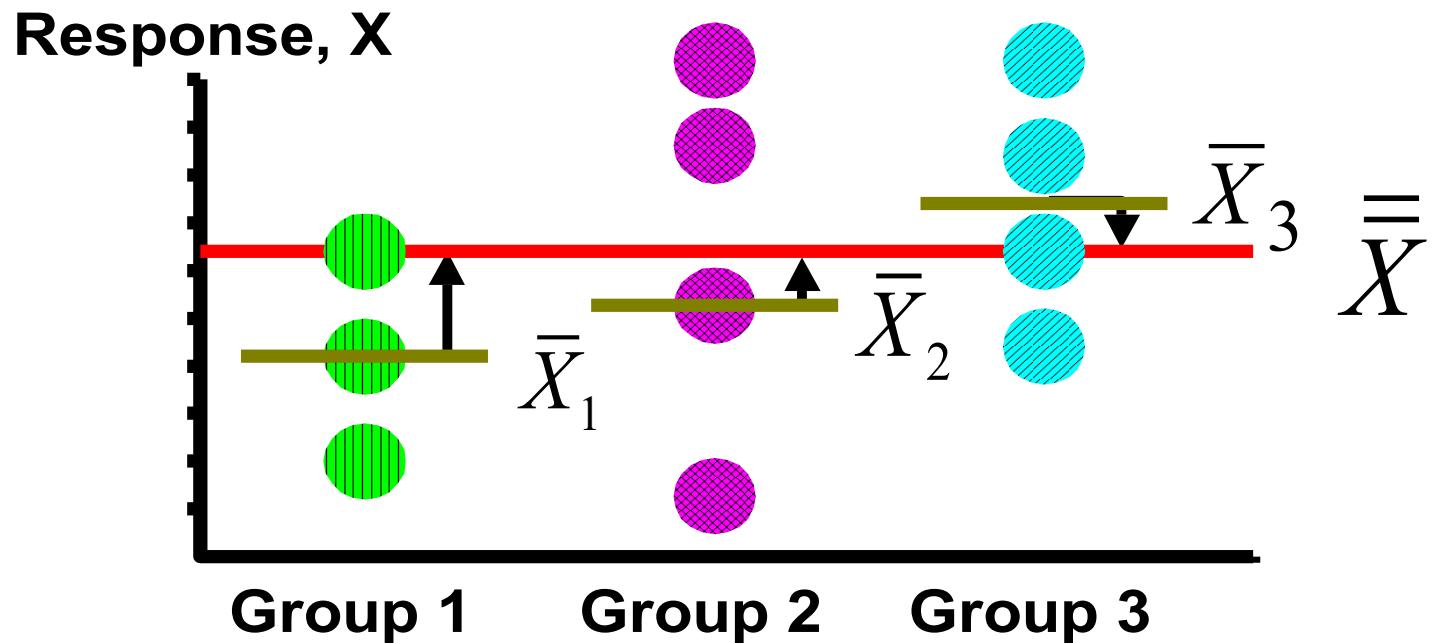
\bar{X}_i = 第*i*组的平均值

$\bar{\bar{X}}$ = 所有数值的平均值

解构变异

组间变异

$$SS_{\text{组间}} = n_1(\bar{X}_1 - \bar{\bar{X}})^2 + n_2(\bar{X}_2 - \bar{\bar{X}})^2 + \dots + n_c(\bar{X}_c - \bar{\bar{X}})^2$$

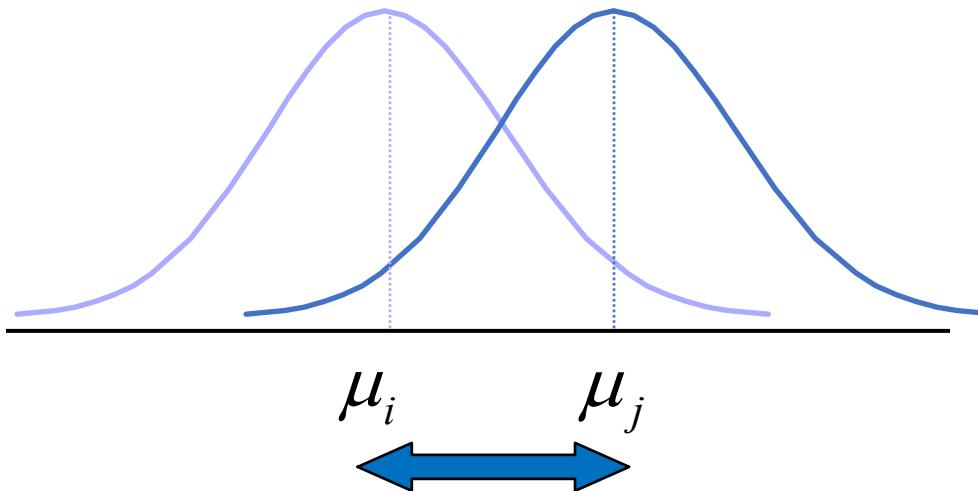


解构变异

组间平均变异

$$SS_{\text{组间}} = \sum_{i=1}^c n_i (\bar{X}_i - \bar{\bar{X}})^2$$

组间变异



$$MS_{\text{组间}} = \frac{SS_{\text{组间}}}{c - 1}$$

组间均方= 组间平方和/自由度

解构变异

组内变异

$$SS_{\text{总}} = SS_{\text{组间}} + SS_{\text{组内}}$$

$$SS_{\text{组内}} = \sum_{i=1}^c \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2$$

其中，

$SS_{\text{组内}}$ = 组内平方和

c = 组别数

n_i = 第*i*组的数据量

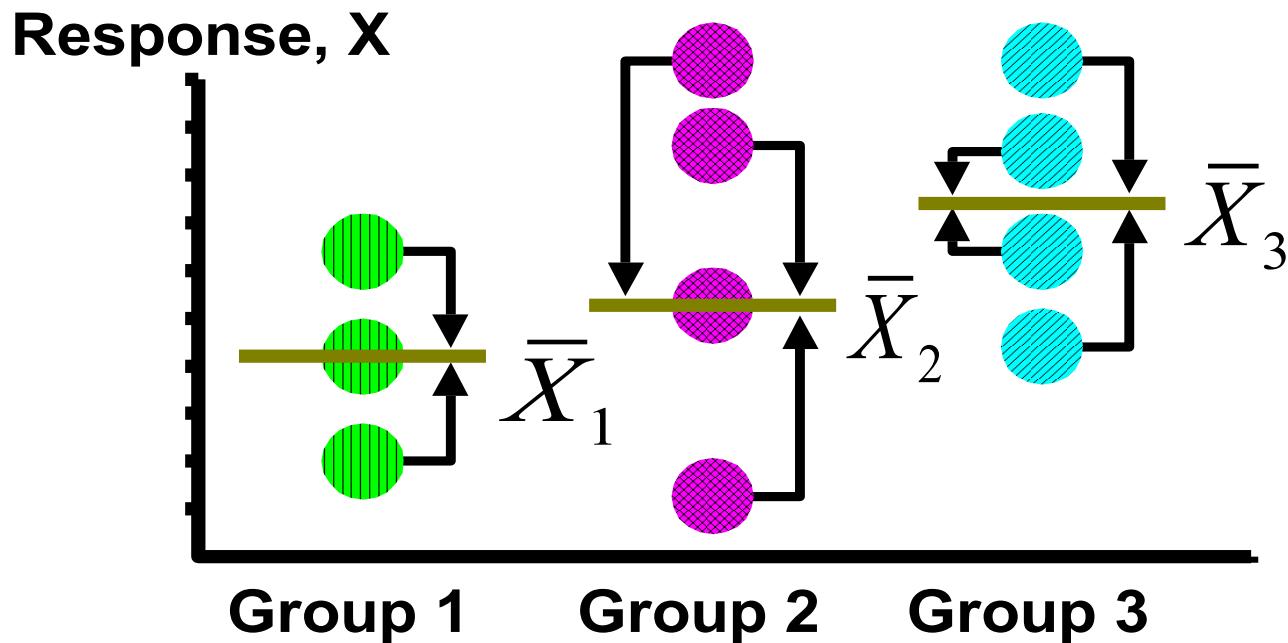
X_{ij} = 第*i*组的第*j*个观测值

\bar{X}_i = 第*i*组的平均值

解构变异

组内变异

$$SS_{\text{组内}} = (X_{11} - \bar{X}_1)^2 + (X_{12} - \bar{X}_1)^2 + \dots + (X_{cn_c} - \bar{X}_c)^2$$

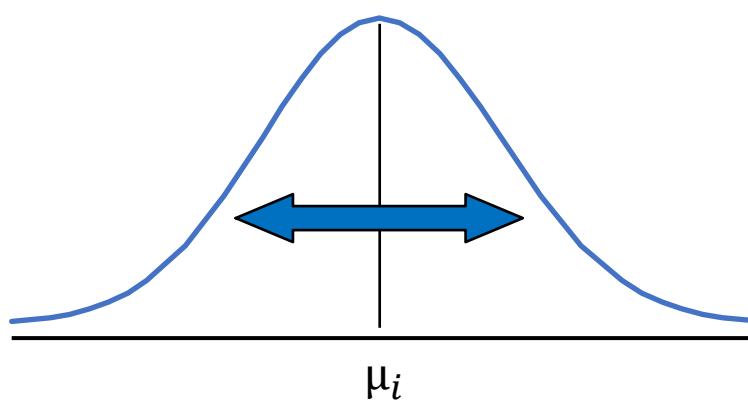


解构变异

组内平均变异

$$SS_{\text{组内}} = \sum_{i=1}^c \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2$$

计算每个组的内部变异，然后将各个组的组内变异数值加总



$$MS_{\text{组内}} = \frac{SS_{\text{组内}}}{n - c}$$

组内均方= 组内平方和/自由度

解构变异

均方

$$MS_{\text{组间}} = \frac{SS_{\text{组间}}}{df_{\text{组间}}}$$

Mean Square Among
($df_{\text{组间}} = c - 1$)

组间均方

$$MS_{\text{组内}} = \frac{SS_{\text{组内}}}{df_{\text{组内}}}$$

Mean Square Within
($df_{\text{组内}} = n - c$)

组内均方

$$MS_{\text{总}} = \frac{SS_{\text{总}}}{n - 1}$$

Mean Square Total
(d.f. = n-1)

总均方



解构变异

单因素方差分析表

变异 (Variance)	平方和 (Sum of Squares, SS)	自由度 (degree of freedom, df)	均方 (Mean Squares, MS)	F
组间	$SS_{\text{组间}}$	$c - 1$	$MS_{\text{组间}}$	$\frac{MS_{\text{组间}}}{MS_{\text{组内}}}$
组内	$SS_{\text{组内}}$	$n - c$	$MS_{\text{组内}}$	
合计	$SS_{\text{总}}$	$n - 1$		

- c : 组别数
- n : 总样本量

- $df_{\text{组间}} = c - 1$
- $df_{\text{组内}} = n - c$

- $MS_{\text{组间}} = \frac{SS_{\text{组间}}}{df_{\text{组间}}}$
- $MS_{\text{组内}} = \frac{SS_{\text{组内}}}{df_{\text{组内}}}$



假设检验

$$H_0: \mu_1 = \mu_2 = \dots = \mu_c$$

H_1 : 至少有两组总体均值不相等

- **检验统计量**

$$F = \frac{MS_{\text{组间}}}{MS_{\text{组内}}}$$

- **自由度**

$$df_1 \quad df_{\text{组间}} = c - 1 \quad (c = \text{组别数})$$

$$df_2 \quad df_{\text{组内}} = n - c \quad (n = \text{总样本量})$$

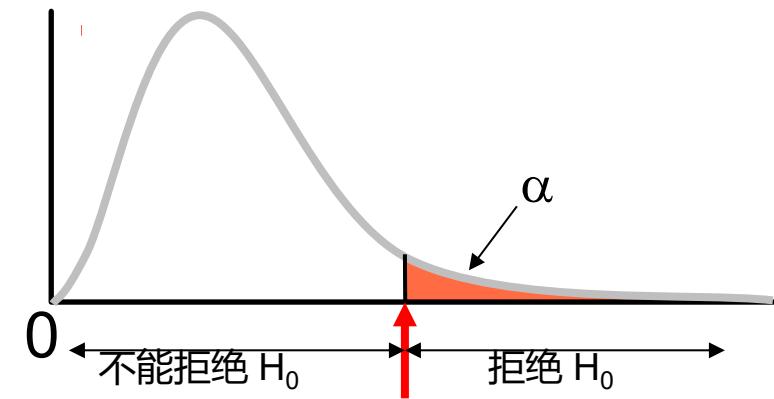


假设检验

假设检验决策：

如果F统计量 $> F_{\alpha}$, 则拒绝 H_0 , 否则不能拒绝 H_0

注：在方差分析中我们只关心组间均方是否显著大于组内均方；如果组间均方小于组内均方，就无须检验其是否小到显著水平，因而我们进行的是单侧检验。



临界值 F_{α}

例题

为了了解三家高尔夫球俱乐部的会员高尔夫球的水平是否有差异，随机各从三家俱乐部挑出5位会员，测试他们打高尔夫球的平均距离。

<u>Club 1</u>	<u>Club 2</u>	<u>Club 3</u>
254	234	200
263	218	222
241	235	197
237	227	206
251	216	204

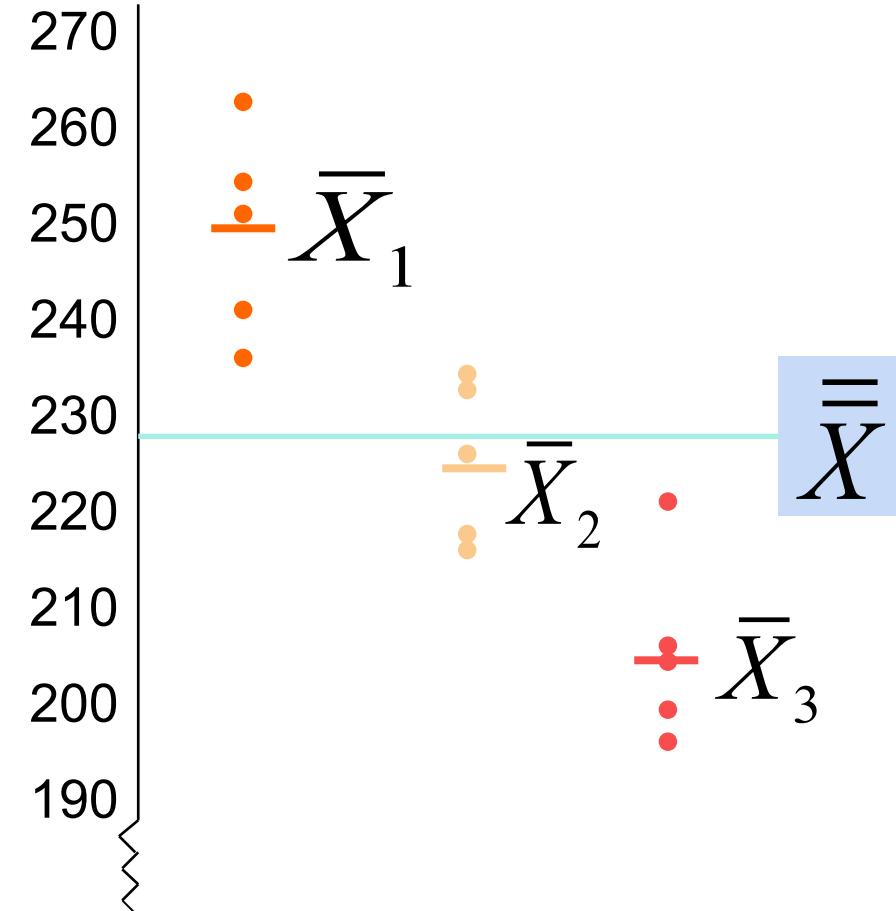


例題

Club 1	Club 2	Club 3
254	234	200
263	218	222
241	235	197
237	227	206
251	216	204

↓

$\bar{x}_1 = 249.2$	$\bar{x}_2 = 226.0$	$\bar{x}_3 = 205.8$
$\bar{\bar{x}} = 227.0$		



例題

<u>Club 1</u>	<u>Club 2</u>	<u>Club 3</u>
254	234	200
263	218	222
241	235	197
237	227	206
251	216	204

→ $\bar{X}_1 = 249.2 \quad n_1 = 5$
 $\bar{X}_2 = 226.0 \quad n_2 = 5$
 $\bar{X}_3 = 205.8 \quad n_3 = 5$
 $\bar{\bar{X}} = 227.0 \quad n = 15$
 $c = 3$

$$SS_{\text{组间}} = 5(249.2 - 227)^2 + 5(226 - 227)^2 + 5(205.8 - 227)^2 = 4716.4$$

$$SS_{\text{组内}} = (254 - 249.2)^2 + (263 - 249.2)^2 + \dots + (204 - 205.8)^2 = 1119.6$$

$$MS_{\text{组间}} = 4716.4 / (3-1) = 2358.2$$

$$MS_{\text{组内}} = 1119.6 / (15-3) = 93.3$$

$$F = \frac{2358.2}{93.3} = 25.275$$

例题

$$H_0: \mu_1 = \mu_2 = \mu_3$$

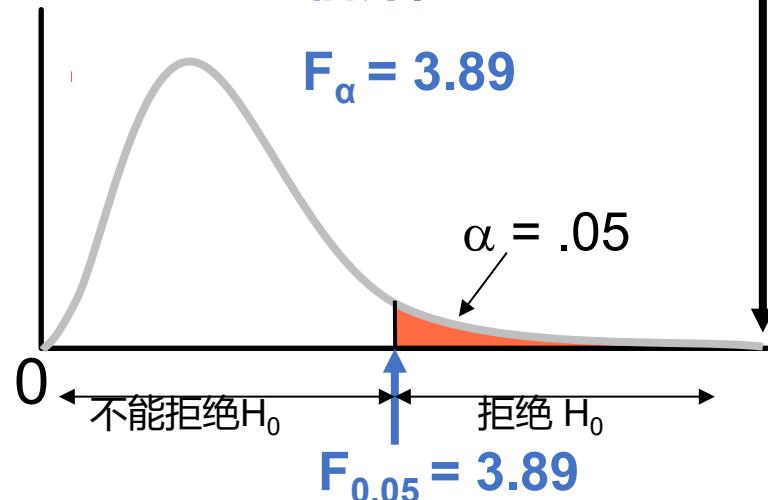
H_1 :不是所有的 μ_i 都相等

$$\alpha = 0.05$$

$$df_1 = 2 \quad df_2 = 12$$

临界值:

$$F_{\alpha} = 3.89$$



检验统计量:

$$F = \frac{MS_{\text{组间}}}{MS_{\text{组内}}} = \frac{2358.2}{93.3} = 25.275$$

假设检验决策:

在 $\alpha = 0.05$ 的水平下拒绝 H_0

结论:

三家俱乐部成员的球技并非完全一致
(至少有一家俱乐部的成员与其它俱乐部成员球技有显著差异)

例题

ANOVA

距离

	平方和	自由度	均方	F	显著性
组间	4716.400	2	2358.200	25.275	.000
组内	1119.600	12	93.300		
总计	5836.000	14			

练习

三个小组成员的成绩有差异吗？

第一组	第二组	第三组
82	79	83
81	80	84
82	80	83
82	81	85
83	80	85

$$\bar{X}_1 = 82$$

$$\bar{X}_2 = 80$$

$$\bar{X}_3 = 84$$

$$\bar{\bar{X}} = 82$$

软件实操



【工具】>【数据分析】>【方差分析：单因素方差分析】>选择数据范围



软件实操

方差分析：单因素方差分析

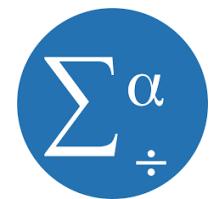
SUMMARY

组	观测数	求和	平均	方差
列 1	5	1246	249.2	108.2
列 2	5	1130	226	77.5
列 3	5	1029	205.8	94.2

方差分析

差异源	SS	df	MS	F	P-value	F crit
组间	4716.4	2	2358.2	25.27546	4.98524E-05	3.885293835
组内	1119.6	12	93.3			
总计	5836	14				

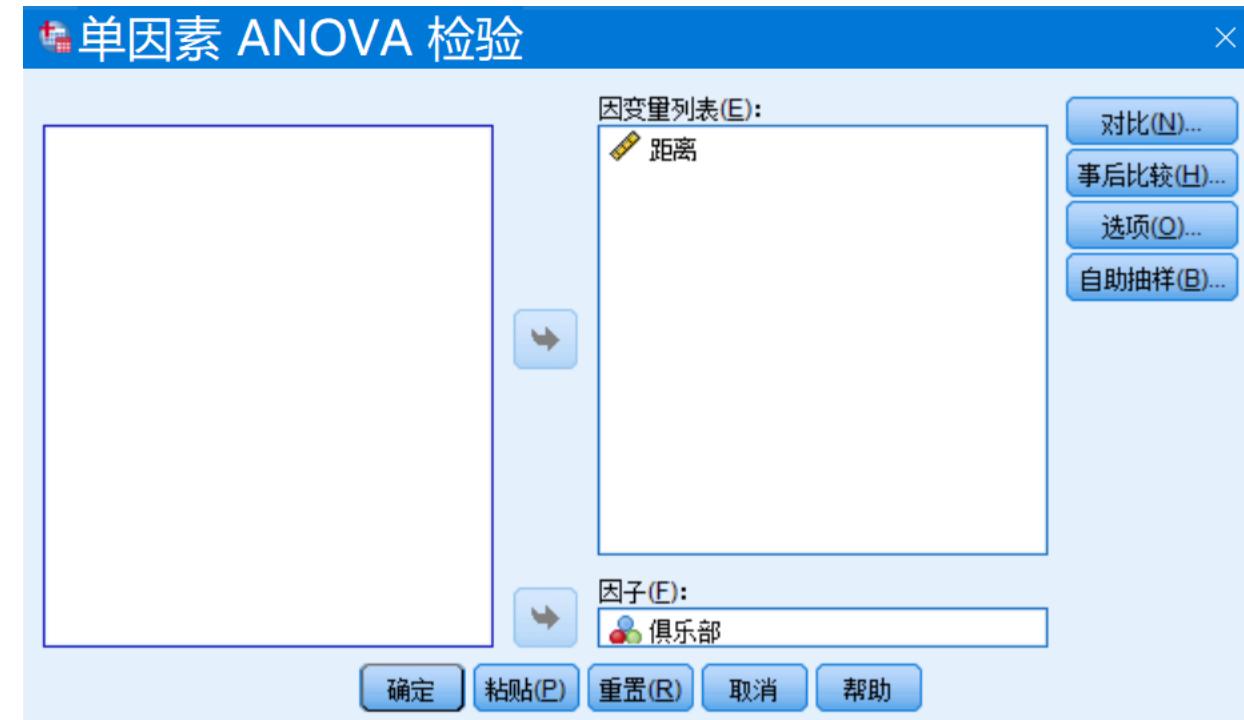
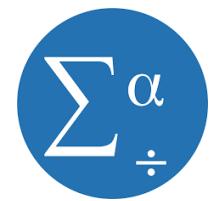
软件实操



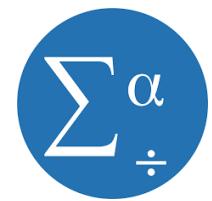
将数据整理成右图的形式

距离	俱乐部
254.00	1.00
263.00	1.00
241.00	1.00
237.00	1.00
251.00	1.00
234.00	2.00
218.00	2.00
235.00	2.00
227.00	2.00
216.00	2.00
200.00	3.00
222.00	3.00
197.00	3.00
206.00	3.00
204.00	3.00

软件实操



软件实操

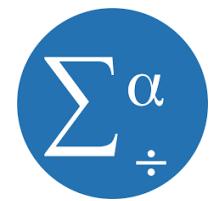


单因素分析中，只要有任意两组平均值不相等我们就可以拒绝原假设了，那么如果想知道具体是哪两组均值不相等呢？**使用事后检验中的LSD方法（可以简单理解为做多个t检验）**

The image shows two overlapping dialog boxes from SPSS:

- 左侧对话框 (单因素 ANOVA 检验):**
 - 因变量列表(E): 距离
 - 因子(F): 俱乐部
 - 按钮: 对比(N)... (被红色圆圈包围)
 - 其他按钮: 事后比较(H)..., 选项(O)..., 自助抽样(B)...
- 右侧对话框 (单因素 ANOVA 检验: 事后多重比较):**
 - 假定等方差:
 - LSD
 - 邦弗伦尼(B)
 - 斯达克(I)
 - 雪费(C)
 - R-E-G-W F
 - R-E-G-W Q
 - S-N-K
 - 图基(I)
 - 图基 s-b(K)
 - 邓肯(D)
 - 霍赫伯格 GT2(H)
 - 加布里埃尔(G)
 - 1类II类误差率: 100
 - 控制类别(Y): 最后一个
 - 检验:
 - 双侧(2)
 - <控制(O)
 - >控制(N)
 - 不假定等方差:
 - 塔姆黑尼 T2(M)
 - 邓尼特 T3
 - 盖姆斯-豪厄尔(A)
 - 邓尼特 C(U)
 - 显著性水平(E): 0.05

软件实操



单因素 ANOVA 检验

因变量列表(E): 距离

因子(F): 俱乐部

对比(N)...
事后比较(H)...
选项(O)...
自助抽样(B)...

统计
 描述(D)
 固定和随机效应(E)
 方差齐性检验(H)
 布朗-福塞斯(B)
 韦尔奇(W)

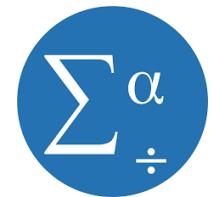
平均值图(M)

缺失值
 按具体分析排除个案(A)
 成列排除个案(L)

继续(C) 取消 帮助



软件实操

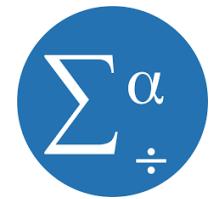


ANOVA

距离

	平方和	自由度	均方	F	显著性
组间	4716.400	2	2358.200	25.275	.000
组内	1119.600	12	93.300		
总计	5836.000	14			

软件实操



事后检验

多重比较

因变量：距离

LSD

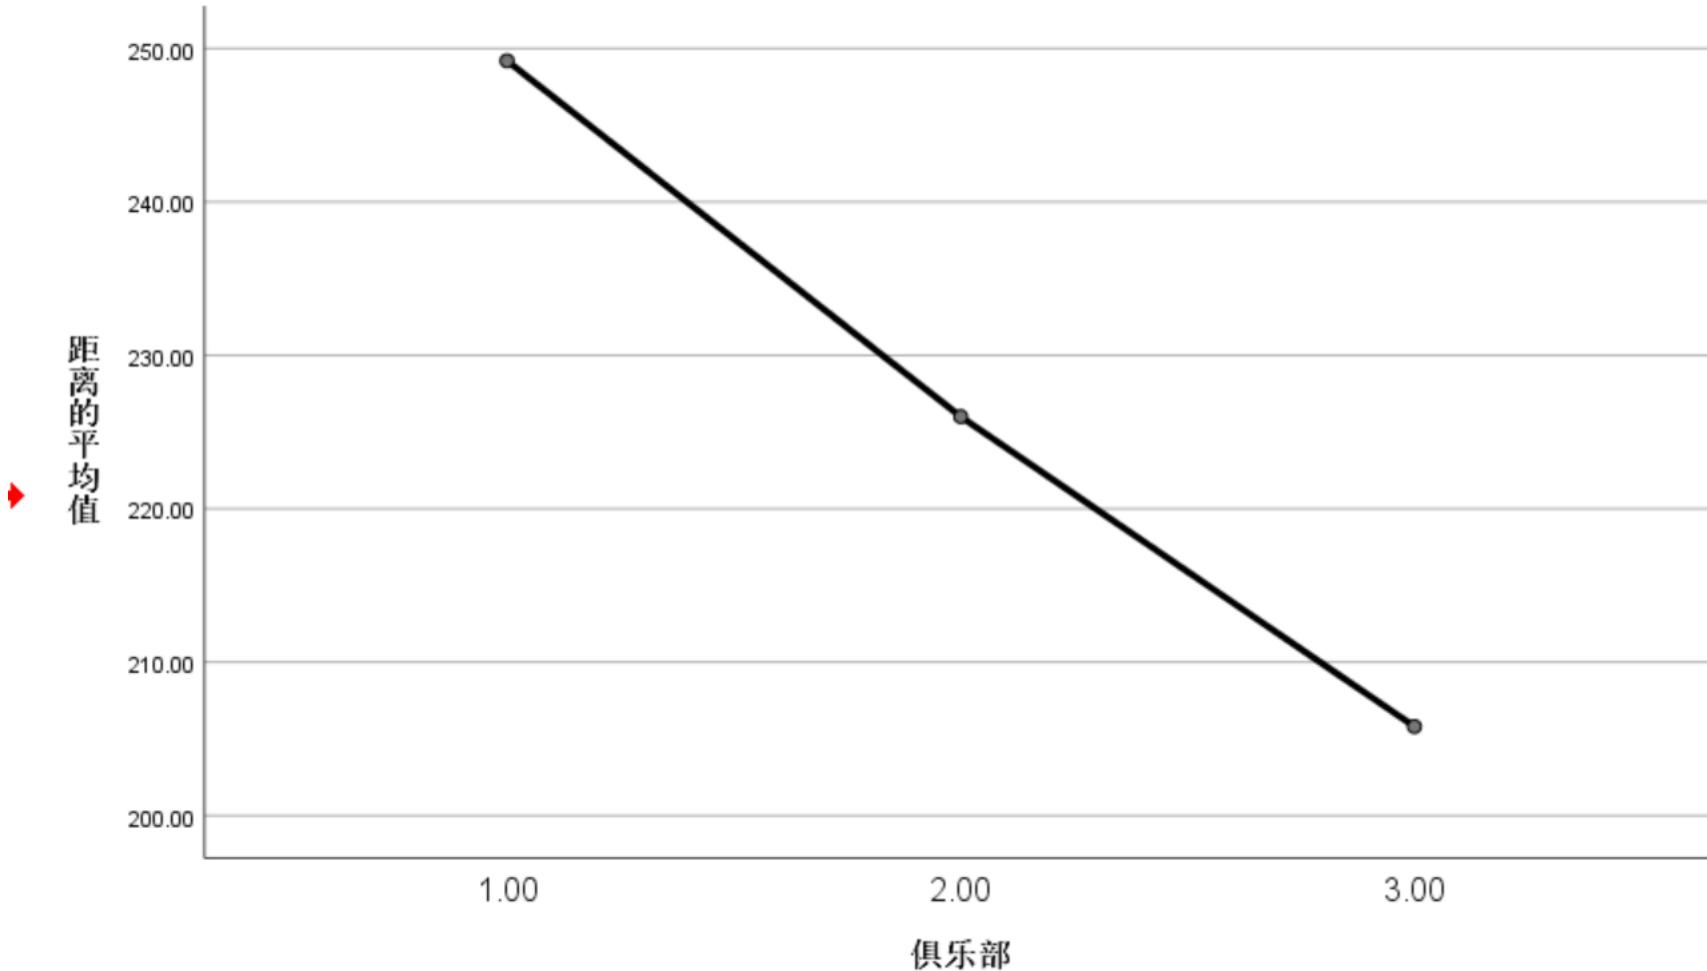
(I) 俱乐部	(J) 俱乐部	J)	平均值差值 (I-	标准 错误	显著性	95% 置信区间	
						下限	上限
1.00	2.00	23.20000*	6.10901	.003	.000	9.8896	36.5104
	3.00	43.40000*	6.10901			30.0896	56.7104
2.00	1.00	-23.20000*	6.10901	.003	.006	-36.5104	-9.8896
	3.00	20.20000*	6.10901			6.8896	33.5104
3.00	1.00	-43.40000*	6.10901	.000	.006	-56.7104	-30.0896
	2.00	-20.20000*	6.10901			-33.5104	-6.8896

*: 平均值差值的显著性水平为 0.05。

软件实操

$\sum \alpha \div$

平均值图



谢谢！